

Professora Inês Dutra

Tópicos Avançados em Inteligência Artificial

Terceiro Relatório: Inferência e Aprendizagem em Programas
de Lógica Probabilística Usando Fórmulas Booleanas Pesadas

Outubro de 2022

Trabalho realizado por:

Pedro Leite - 201906697

1. Questões Gerais

1.1. Sobre o que é que este projeto fala?

O projeto investiga a maneira ide como a inferência clássica e tarefas de aprendizagem, podem ser utilizadas para programas de lógica probabilística. São apresentadas duas contribuições: a primeira é um conjunto de algoritmos eficientes para várias tarefas de inferência, a segunda é um algoritmo para estimativa de parâmetros na aprendizagem de configurações de interpretações.

1.2. O que o diferencia?

Há muito interesse na combinação de probabilidades e de lógica para lidar com domínios de relação complexos. Este interesse resulta nos campos *Probabilistic Logic Programming (PLP)* e *Statistical Relacional Learning (SRL)*. *SRL* foca-se na extensão de modelos gráficos probabilísticos tal como *Markov* ou redes *Bayesianas* com representações lógicas e relacionais. *PLP* estende linguagens de programação lógica com probabilidades. Este projeto junta estas duas comunidades ao adaptar o tradicional modelo gráfico e configurações *SRL* para a perspectiva do *PLP*.

1.3. São apresentadas experiências? Qual é a metodologia apresentada? Parece correto?

O objetivo das experiências é responder às seguintes perguntas:

- Q1: Trabalhar com o programa relevante em vez do programa de solo completo mais eficiente?
- Q2: Qual dos dois algoritmos considerados para converter o programa de solo para uma fórmula booleana (conversão baseada em regras ou baseada em provas), funciona melhor?
- Q3: Qual das duas abordagens consideradas parar compilar conhecimento (*d-DNNFs* ou *BDDs*), performa melhor?
- Q4: Ao computar probabilidades, o *ProbLog2* funciona melhor que a implementação prévia de *ProbLog*?
- Q5: Ao aprender dados gerados de um conhecido programa de *Problog*, podemos recuperar parâmetros do programa original, dado uma quantidade de dados razoável?

- Q6: Ao aprender a partir de dados do mundo real, podemos obter resultados comparáveis aos obtidos no sistema esta da arte (nomeadamente, *Alchemy*)?

Foram definidos vários programas e *datasets*, tal como um *setup* experimental, constituído pelos *setups*: de inferência e de aprendizagem.

Apresentando os seguintes resultados experimentais:

- Q1: Foi concluído que ao utilizar o *RGP* em vez de completar *grounding* é benéfico e quase que não tem qualquer tipo de custo computacional. Então, a partir de agora vão utilizar sempre o *RGP*.
- Q2: Foi concluído que para domínios mais pequenos o algoritmo baseado em prova é preferível porque tem fórmulas mais pequenas. Em domínios maiores, o algoritmo baseado em regras deve ser usado.
- Q3: Foi concluído que o uso de *d-DNNFs* puxa o limite esperado de inferência *MARG* exata, significativamente mais comparado a *BDDs*, o que eram os padrões em *PLP*.
- Q4: Foi concluído que os resultados mostram que *ProbLog2* escala melhor que *ProbLog1*.
- Q5: Foi concluído que *LFI-ProbLog* é capaz de recuperar as probabilidades originais e é robusto contra valores em falta. Quando compararam as figuras para os diferentes tamanhos de domínios, podemos ver que os resultados são independentes do número de pessoas no domínio.
- Q6: *LFI-ProbLog* demonstra uma performance melhor que o *Alchemy*, com as configurações básicas em 3 das 4 dobras. *Alchemy* com o forte anterior, performa melhor que o *LFI-ProbLog* nas 4 dobras. Foi concluído que *LFI-ProbLog* é competitivo com o *Alchemy*, mas o ajuste de parâmetros pode ter um grande impacto. Os resultados ilustram a importância de definir um prior adequado ao aprender.

1.4. Quais são os principais resultados/descobertas/conclusões? Os resultados são relevantes/úteis?

Foi introduzido um processo de dois passos para *MPE* e inferência de *MARG* em programas lógicos probabilísticos em geral.

Foi desenvolvido uma abordagem em *EM* para aprender programas lógicos probabilísticos para interpretações.

As duas abordagens foram incorporadas numa implementação da linguagem e *ProbLog PLP*, onde ao contrário da sua implementação prévia em *YAP-Prolog*, está mais perto dos sistemas *ASP* do que os sistemas *Prolog*.

No geral, as abordagens apresentam novas ideias nas relações entre *PLP*, modelos gráficos e *SRL*. Como uma conclusão imediata, foram apontadas uma conversão de programas lógicos probabilísticos para a lógica de *Markov*, o que permitiu aplicar *MC-SAT* à inferência *PLP*. Isso contribui para diminuir ainda mais a distância entre *PLP* e o campo de *SRL*.